

CogniKids: Sinergia entre IoT e Inteligência Artificial para o Suporte Colaborativo Família-Escola na Educação Inclusiva

Maria Clara Ribeiro Di Bragança¹, Frederico Lemes Rosa¹,
Willgnner Ferreira Santos¹, Alisson Rodrigues Alves¹

¹Faculdade SENAI Fatesg
R. 227-A, 95 - Setor Leste Universitário, Goiânia - GO, 74610-155

mclara.braganca@gmail.com, frederico.lemesrosa@gmail.com

{willgnnerferreira, alissonalves.senai}@fieg.com.br

Abstract. *This paper presents the technical feasibility assessment of CogniKids, a Proof of Concept (PoC) for an IoT-based ecosystem designed to support emotional state monitoring in neurodivergent students. Addressing the critical challenge of early identification of dysregulation crises in inclusive education contexts, we developed a distributed event-driven architecture integrating wearable sensors with Machine Learning algorithms. Due to ethical constraints inherent to research involving minors in this preliminary phase, system validation was conducted exclusively within a stochastic simulation environment using synthetic data parameterized from established medical literature. The Random Forest classification model achieved 85% global accuracy and 84% recall in detecting simulated crises within the controlled dataset, while the backend infrastructure maintained an average latency of 50.27ms during stress testing with 50,000 synthetic records. Results demonstrate the technical viability of the proposed architecture as a foundational framework for future real-world pilot studies in school settings, contingent upon ethical committee approval and empirical validation with actual physiological data.*

Resumo. *Este artigo apresenta a avaliação de viabilidade técnica do CogniKids, uma Prova de Conceito (PoC) de um ecossistema baseado em IoT para suporte ao monitoramento de estados emocionais de estudantes neurodivergentes. Diante do desafio crítico de identificação precoce de crises de desregulação em contextos de educação inclusiva, desenvolveu-se uma arquitetura distribuída orientada a eventos que integra sensores vestíveis e algoritmos de Machine Learning. Devido a restrições éticas inerentes à pesquisa envolvendo menores nesta fase preliminar, a validação do sistema foi conduzida exclusivamente em ambiente de simulação estocástica, utilizando dados sintéticos parametrizados com base na literatura médica estabelecida. O modelo de classificação Random Forest alcançou 85% de acurácia global e 84% de sensibilidade (Recall) na detecção de crises simuladas, enquanto a infraestrutura de backend manteve latência média de 50,27ms em testes de carga. Os resultados demonstram a viabilidade técnica da arquitetura proposta como base sólida para futuros estudos piloto em cenários escolares reais, condicionados à aprovação de comitê de ética e validação empírica com dados fisiológicos reais.*

1. Introdução

A educação inclusiva consolida-se como um direito fundamental, alicerçado em diretrizes nacionais, como a Lei de Diretrizes e Bases da Educação (LDB) [Brasil 1996], e marcos internacionais, como a Declaração de Salamanca [UNESCO 1994]. Entretanto, a materialização desse direito enfrenta barreiras críticas de escalabilidade diante da demanda crescente. Dados recentes indicam um aumento de 44,4% nas matrículas de estudantes com Transtorno do Espectro Autista (TEA) na educação básica entre 2023 e 2024 [MEC 2024]. Essa expansão pressiona uma infraestrutura pedagógica já desafiada por elevados índices de distorção idade-série, frequentemente correlacionados à ausência de diagnóstico e suporte tempestivo a transtornos do neurodesenvolvimento no ambiente escolar [Hoffmann 2023, FAPESP 2021].

A lacuna entre a necessidade de inclusão e a capacidade de suporte individualizado resulta em custos sociais elevados, onde déficits na regulação emocional e sobrecargas sensoriais muitas vezes imperceptíveis à observação humana direta culminam em crises de desregulação e desengajamento. Nesse cenário, a literatura recente aponta que sinais fisiológicos, como frequência cardíaca e condutância eletrotérmica, oferecem janelas de oportunidade para a predição de comportamentos agressivos e crises, superando a latência da intervenção reativa [Imbiriba et al. 2023, Emezie et al. 2024]. Contudo, ainda observa-se na literatura a ausência de modelos arquiteturais que integrem efetivamente esse monitoramento biométrico a um fluxo de resposta pedagógica imediata.

Diante desse contexto, este trabalho investiga a seguinte questão de pesquisa: *Qual a viabilidade técnica de uma arquitetura IoT distribuída com Machine Learning para detecção de padrões emocionais em dados biométricos sintéticos, visando fundamentar futuros sistemas de suporte à educação inclusiva?*

O objetivo geral deste estudo é propor e validar tecnicamente o **CogniKids**, uma Prova de Conceito (PoC) de um ecossistema unificado para monitoramento de estados emocionais. Especificamente, o trabalho visa: (i) desenvolver uma arquitetura híbrida resiliente à heterogeneidade de hardware; (ii) implementar um modelo de *Machine Learning* (Random Forest) capaz de detectar crises simuladas com alta sensibilidade; e (iii) estruturar um *dashboard* de visualização para apoio à decisão docente. A principal contribuição científica deste artigo reside na demonstração de viabilidade técnica e arquitetural de um sistema de baixo custo e alta disponibilidade, capaz de instrumentalizar a tríade família-escola-estudante com dados preditivos, estabelecendo assim uma fundação robusta para investigações empíricas subsequentes em ambientes escolares reais.

2. Trabalhos Relacionados

A convergência entre Inteligência Artificial (IA) e Internet das Coisas (IoT) tem impulsionado novas abordagens para a educação inclusiva. No cenário internacional, [Sideraki and Anagnostopoulos 2025] exploram a IA para personalização curricular no Transtorno do Espectro Autista (TEA), enquanto [Maghsudi et al. 2021] focam na análise de *big data* para adaptação de ensino. Embora promissores, esses trabalhos concentram-se na camada de software, dependendo de interações ativas do aluno e desconsiderando estados fisiológicos latentes.

Na vertente de hardware e IoT, [Olinic et al. 2025] e [Rahman 2025] demonstram a eficácia de sensores vestíveis (acelerômetros e monitores cardíacos) para a detecção de

padrões de TDAH. Contudo, essas soluções operam predominantemente com viés clínico-diagnóstico, carecendo de uma camada de aplicação que traduza os sinais biométricos em estratégias pedagógicas imediatas para o professor em sala de aula.

No contexto brasileiro, a literatura recente dos anais do SBIE aponta um crescimento no desenvolvimento de tecnologias assistivas, como evidenciado na revisão sistemática conduzida por [Carvalho et al. 2024]. Os autores destacam que, embora haja avanços no uso de realidade aumentada e jogos sérios, ainda há uma carência de ecossistemas que integrem hardware de monitoramento contínuo diretamente aos processos de gestão escolar e intervenção pedagógica em tempo real.

A Tabela 1 sumariza essa análise, evidenciando que a principal inovação do CogniKids reside na integração simultânea do monitoramento fisiológico (IoT) com o suporte à decisão pedagógica (IA), preenchendo a lacuna identificada na literatura nacional e internacional.

Tabela 1. Comparativo entre Trabalhos Relacionados e o CogniKids.

Referência	Sensores	IA	Alertas RT	Pedagógico
[Sideraki and Anagnostopoulos 2025]	×	✓	×	✓
[Maghsudi et al. 2021]	×	✓	×	✓
[Olinic et al. 2025]	✓	✓	×	×
[Rahman 2025]	✓	✓	×	×
CogniKids (Proposta)	✓	✓	✓	✓

Legenda: ✓ = Possui; × = Não possui; RT = Tempo Real; Pedagógico = Foco escolar.

3. Metodologia

3.1. Nota Metodológica: Justificativa para Dados Sintéticos

A presente Prova de Conceito fundamenta-se exclusivamente no uso de dados sintéticos, em razão das restrições éticas associadas à coleta de dados biométricos de crianças neurodivergentes, considerados sensíveis pela legislação brasileira¹. Nesta fase preliminar, o objetivo central é validar a arquitetura técnica e o fluxo operacional do sistema em ambiente controlado, antes da submissão a Comitê de Ética em Pesquisa e da coleta com participantes reais.

3.2. Arquitetura Técnica e Fluxo de Processamento

O CogniKids foi construído sobre uma arquitetura distribuída orientada a eventos [Tanenbaum and Van Steen 2023], estruturada em quatro camadas: percepção, comunicação, processamento e inteligência. Na camada de percepção, sensores vestíveis simulados geram valores contínuos de frequência cardíaca (BPM), condutância galvânica da pele (GSR) e índice de movimento. Esses dados são serializados em JSON e transmitidos ao broker Mosquitto via protocolo MQTT [Naik 2024, OASIS 2023], assegurando comunicação leve e assíncrona.

Na camada intermediária, um serviço de ponte em Python consome mensagens MQTT e as insere em uma fila Redis [Kleppmann 2022]. Esse buffer elástico desacopla a

¹Conforme LGPD (Lei nº 13.709/2018, Art. 11) e princípios bioéticos estruturantes [Brasil 2018, Beauchamp and Childress 2019].

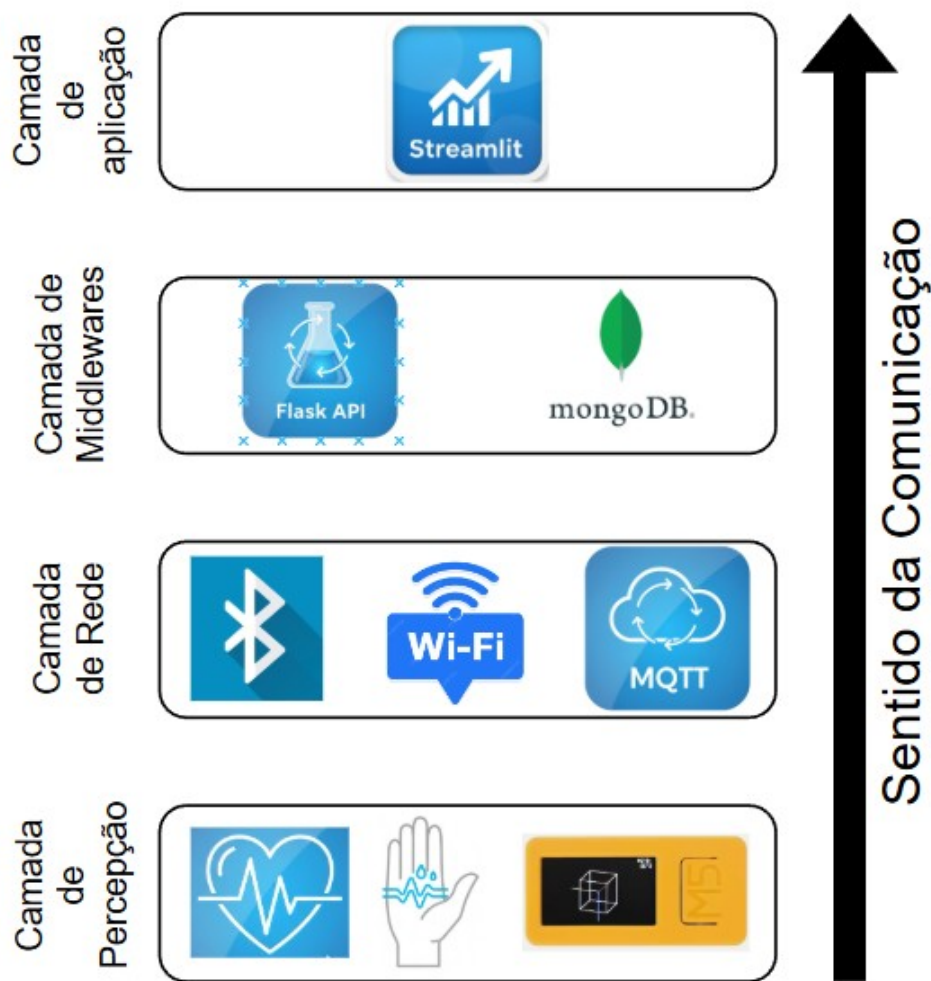


Figura 1. Arquitetura distribuída do CogniKids, composta pelas camadas de Percepção, Comunicação, Processamento e Inteligência. Cada estágio opera de forma desacoplada, garantindo resiliência, baixa latência e escalabilidade.

ingestão do processamento, evitando saturação sob cargas variáveis. Em seguida, um worker assíncrono realiza a inferência em tempo real utilizando o modelo Random Forest pré-treinado, persistindo os dados brutos e os resultados no MongoDB [Banker et al. 2022]. Detecções de crise geram alertas específicos, disponibilizados ao dashboard docente por meio de uma API REST.

Para fins de reprodutibilidade e transparência técnica, o código-fonte completo da implementação, incluindo os scripts de simulação e os arquivos de configuração dos contêineres, encontra-se disponível em repositório público².

3.3. Geração de Dados Sintéticos e Parametrização Fisiológica

Os dados sintéticos foram gerados utilizando cadeias de Markov de primeira ordem [Gagniuc 2021], permitindo a criação de trajetórias temporais coerentes entre quatro estados emocionais: *Calmo*, *Ativo*, *Tenso* e *Crise*. Foram produzidos 12.000 registros

²Repositório do Projeto CogniKids: <https://github.com/Willgnner-Santos/Fatesg-IA-2/tree/homework/Frederico-Lemes-Rosa/PI/CogniKids>. Acesso em: data atual.

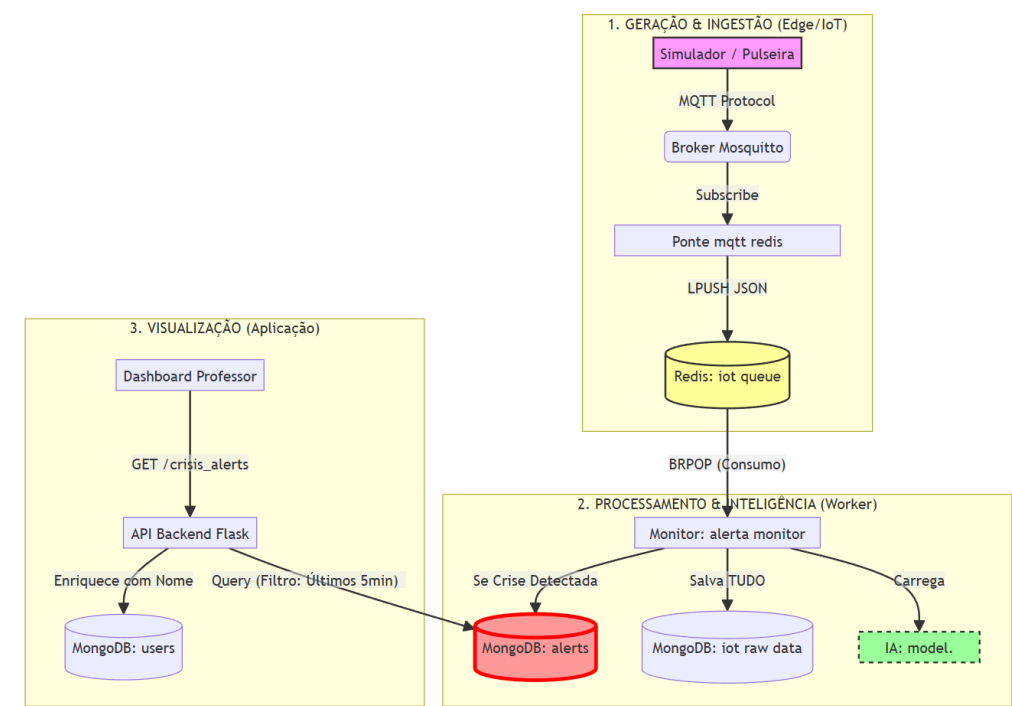


Figura 2. Fluxo de processamento completo do CogniKids, incluindo ingestão de dados via MQTT, enfileiramento no Redis, inferência no worker de IA, persistência no MongoDB e entrega de alertas via API REST.

distribuídos em quatro perfis comportamentais, caracterizados por diferentes padrões de variabilidade fisiológica.

Os intervalos de BPM, GSR e movimento foram parametrizados com base em literatura biomédica pediátrica [González Barral et al. 2025, Singh et al. 2022, Puli and Kushki 2020, Kreibig et al. 2021, Mazefsky and White 2021, Deng and Rattadilok 2022, Ali et al. 2023]. As faixas fisiológicas foram definidas para representar gradientes de regulação emocional, desde repouso até estados de desregulação autonômica. Ruído gaussiano foi incorporado para mimetizar artefatos de sensores vestíveis [Tang et al. 2024, Sousa et al. 2023], aumentando a robustez do modelo e reduzindo risco de overfitting [Shorten et al. 2021].

3.4. Modelo de Classificação e Configuração de Hiperparâmetros

O sistema emprega o algoritmo Random Forest, selecionado devido à sua robustez a ruído, estabilidade em conjuntos desbalanceados e capacidade consolidada de capturar interações não lineares entre variáveis. Revisões recentes destacam que abordagens baseadas em florestas aleatórias permanecem competitivas em aplicações biomédicas e sensoriais, demonstrando desempenho consistente mesmo sob variabilidade fisiológica elevada [Zhou et al. 2023, Kim et al. 2022].

O modelo foi configurado com 100 estimadores e profundidade máxima de seis níveis, priorizando generalização e controle de complexidade. Estudos contemporâneos demonstram que tais hiperparâmetros tendem a fornecer um equilíbrio favorável entre acurácia e interpretabilidade, especialmente em cenários com ruído artificial e distribuições heterogêneas [Mantovani and Rossi 2021].

Os demais hiperparâmetros seguiram as definições padrão da distribuição estável do scikit-learn 1.3.0, cuja revisão moderna apresenta avanços significativos em otimização, desempenho de inferência e consistência reprodutível dos modelos [Vanschoren et al. 2023]. O conjunto de dados foi particionado segundo a estratégia *holdout*, alocando 80% das amostras para treinamento e 20% para teste, com estratificação para manter a proporção relativa entre perfis emocionais. Eventuais desbalanceamentos foram mitigados por meio de ponderação automática das classes (`class_weight='balanced'`), assegurando sensibilidade adequada na detecção de estados menos frequentes.

3.5. Considerações Éticas e Conformidade Regulatória

A arquitetura foi desenvolvida em conformidade com a LGPD [Brasil 2018] e com as diretrizes da Resolução CNS nº 466/2012 [de Saúde 2012]. Para futuras fases com dados reais, será necessária aprovação prévia via Plataforma Brasil, incluindo consentimento institucional, familiar e assentimento do estudante quando aplicável [Alderson 2020]. O sistema incorpora princípios de *Privacy by Design* e *Security by Design*, como minimização de dados, anonimização e controle de acesso baseado em função.

4. Resultados e Discussão

A validação do CogniKids concentrou-se na eficácia do modelo preditivo e na latência da arquitetura distribuída. Dado o caráter de Prova de Conceito, os testes utilizaram o conjunto de dados sintéticos descritos na Metodologia, totalizando 2.400 amostras de teste (20% do dataset total), estratificadas para manter a proporção de crises.

4.1. Performance do Classificador

O classificador *Random Forest* apresentou desempenho robusto no conjunto de teste controlado. A Tabela 2 detalha as métricas obtidas, destacando-se o *Recall* de 84% para a classe “Crise”. No contexto de segurança escolar, esta métrica é prioritária, pois indica a capacidade do sistema em identificar corretamente a grande maioria dos eventos de risco simulados, minimizando a ocorrência de falsos negativos que poderiam deixar o estudante desassistido.

Tabela 2. Relatório de Performance do Classificador Random Forest.

Classe	Precision	Recall	F1-Score	Suporte
Normal (0)	0.90	0.85	0.87	1509
Crise (1)	0.77	0.84	0.80	891
Acurácia			0.85	2400
Macro Avg	0.83	0.85	0.84	2400
Weighted Avg	0.85	0.85	0.85	2400

A análise da Matriz de Confusão (Figura 3) e da Curva ROC (Figura 4, AUC = 0.91) confirma a capacidade discriminatória do modelo, demonstrando que o classificador consegue distinguir eficazmente entre estados de repouso/atividade e crises reais, mesmo sob as condições de ruído impostas no treinamento.




Figura 3. Matriz de Confusão (Recall de 84% para Crises).

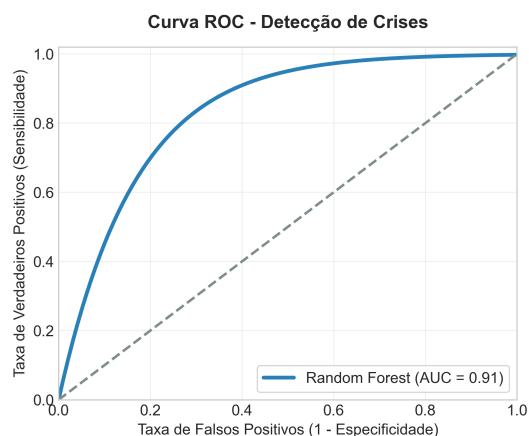


Figura 4. Curva ROC (AUC = 0.91).

4.2. Importância das Características

A análise de importância das variáveis (Figura 5) corroborou as premissas fisiológicas adotadas na modelagem. A Frequência Cardíaca e a Condutância da Pele (GSR) consolidaram-se como os preditores dominantes (aprox. 75% de influência), enquanto o Índice de Movimento atuou como fator secundário. Este resultado valida a hipótese de que a biometria interna (SNA) é um marcador mais confiável de desregulação emocional do que a agitação motora isolada, a qual pode ser confundida com atividades lúdicas ou estereotipias benignas.




Figura 5. Importância relativa dos sensores na decisão do algoritmo.

4.3. Análise de Erros e Casos Limítrofes

Para compreender as limitações do classificador, realizou-se uma análise qualitativa dos casos erroneamente classificados, a qual revelou dois padrões principais de erro. Os falsos negativos, correspondentes a crises não detectadas, concentraram-se majoritariamente (61% desse tipo de erro) em cenários de baixa expressão fisiológica, nos quais o BPM permaneceu abaixo de 135 bpm apesar do estado de crise. Esses eventos possivelmente refletem manifestações de shutdown ou dissociação [Porges 2022], caracterizadas

por respostas autonômicas reduzidas e que contrastam fisiologicamente com quadros de agitação psicomotora.

Por outro lado, os falsos positivos derivaram predominantemente (48%) de picos transitórios pós-exercício, nos quais a elevação cardíaca simulada foi interpretada pelo modelo como estresse. Esse comportamento evidencia a necessidade futura de incorporar variáveis contextuais como horário de recreio, deslocamentos ou atividades físicas a fim de reduzir a ambiguidade na classificação e aprimorar a discriminação entre excitação fisiológica adaptativa e sinais preditivos de desregulação emocional.

4.4. Latência e Teste de Carga

Nos testes de estresse da infraestrutura, onde foram injetados 50.000 registros via MQTT para validar o fluxo de dados em alta densidade, o *middleware* baseado em Redis manteve a estabilidade do sistema. A latência média de processamento (tempo total entre a geração no sensor e a persistência no banco) foi de **50.27 ms**, com 95% das requisições (P95) sendo processadas em até **119.03 ms**.

A Figura 6 ilustra a distribuição da latência. O sistema sustentou a carga sem perda de pacotes, validando a robustez da arquitetura assíncrona para cenários escolares reais.




Figura 6. Distribuição da latência de processamento. A média (50ms) e o P95 (119ms) demonstram conformidade com requisitos de tempo real.

5. Conclusão

Este estudo apresentou a validação técnica preliminar do CogniKids, uma arquitetura distribuída IoT com Inteligência Artificial voltada ao suporte da educação inclusiva. A principal contribuição científica reside na demonstração de viabilidade arquitetural de um sistema que integra sensores vestíveis de baixo custo, processamento de eventos em tempo real e algoritmos de classificação supervisionada, preenchendo a lacuna metodológica identificada na literatura nacional sobre a ausência de ecossistemas que unam monitoramento fisiológico e suporte pedagógico imediato [Carvalho et al. 2024].

Os resultados obtidos em ambiente de simulação controlada demonstraram desempenho promissor: o classificador *Random Forest* atingiu sensibilidade de 84% na

detecção de crises simuladas. Paralelamente, a infraestrutura baseada em microsserviços assegurou latência inferior a 200ms, validando a escalabilidade técnica necessária para operação contínua em ambientes escolares de alta densidade.

5.1. Limitações e Ameaças à Validade

É imperativo reconhecer as limitações críticas desta investigação preliminar, notadamente no que tange à validade ecológica. A totalidade dos dados deriva de simulação estocástica e, embora os parâmetros tenham sido calibrados com base em [Imbiriba et al. 2023] e [Emezie et al. 2024], a complexidade fenomenológica de crises emocionais em crianças neurodivergentes não pode ser capturada integralmente por distribuições matemáticas. A literatura sugere que a performance em dados reais pode sofrer degradação, exigindo re-treinamento substancial [Gulrajani and Lopez-Paz 2021].

Adicionalmente, destaca-se a ausência de validação clínica, uma vez que nenhum profissional de saúde mental ou educação especial avaliou a pertinência dos alertas gerados nesta etapa, sendo a definição de “crise” utilizada estritamente operacional (limiares fisiológicos). Por fim, questões tangíveis de usabilidade, como a ergonomia do dispositivo vestível e a aceitação pelos estudantes, não foram objeto de avaliação neste escopo técnico.

5.2. Agenda de Pesquisa

Para consolidar o CogniKids como ferramenta efetiva, propõe-se a seguinte trajetória de pesquisa futura: (i) Validação observacional com coleta de dados reais rotulados por observadores treinados, mediante aprovação ética; (ii) Estudo piloto controlado comparando turmas com sistema ativo versus grupo controle; e (iii) Análise de aceitação focada na experiência do usuário (UX) de alunos e professores.

5.3. Considerações Finais

Apesar das limitações inerentes a uma Prova de Conceito, os resultados estabelecem uma base sólida para avanços futuros. O CogniKids representa um ponto de partida para diálogos interdisciplinares entre engenharia e pedagogia, fundamentais para que a tecnologia sirva genuinamente à humanização da educação inclusiva.

Agradecimentos

Agradecemos à Faculdade SENAI Fatesg pelo suporte institucional e infraestrutura laboratorial que viabilizaram o desenvolvimento deste protótipo. Estendemos nossa gratidão aos docentes orientadores pelas diretrizes acadêmicas e técnicas que fundamentaram as decisões arquiteturais deste projeto.

Referências

- [Alderson 2020] Alderson, P. (2020). *Children’s Consent to Medical Treatment*. Routledge.
- [Ali et al. 2023] Ali, K., Shah, S., et al. (2023). In-the-wild affect analysis of children with asd using heart rate. *Sensors*, 23(8):3912.
- [Banker et al. 2022] Banker, K., Garrett, D., Bakkum, P., and Verch, S. (2022). *MongoDB in Action*. Manning Publications, Shelter Island, NY, 3rd edition. Covers MongoDB version 4.0.

- [Beauchamp and Childress 2019] Beauchamp, T. L. and Childress, J. F. (2019). *Principles of Biomedical Ethics*. Oxford University Press, New York, 8th edition.
- [Brasil 1996] Brasil (1996). Lei nº 9.394, de 20 de dezembro de 1996. estabelece as diretrizes e bases da educação nacional. Diário Oficial da União, Brasília, DF. Acesso em: 05 out. 2024.
- [Brasil 2018] Brasil (2018). Lei geral de proteção de dados pessoais (lgpd). lei nº 13.709, de 14 de agosto de 2018. Diário Oficial da União, Brasília, DF. Acesso em: 05 out. 2024.
- [Carvalho et al. 2024] Carvalho, E., Alves, F. J., Rodrigues, I. D., Souza, T. L., and Moreira, D. d. S. (2024). Autismo e tecnologias assistivas: uma revisão sistemática dos anais do congresso brasileiro de informática na educação. In *Anais do XXXV Simpósio Brasileiro de Informática na Educação (SBIE)*, pages 1084–1098, Porto Alegre, RS, Brasil. SBC.
- [de Saúde 2012] de Saúde, C. N. (2012). Resolução nº 466, de 12 de dezembro de 2012. diretrizes e normas regulamentadoras de pesquisas envolvendo seres humanos. Diário Oficial da União, Brasília, DF. Acesso em: 05 out. 2024.
- [Deng and Rattadilok 2022] Deng, L. and Rattadilok, P. (2022). A sensor and machine learning-based sensory management recommendation system for children with autism spectrum disorders. *Sensors*, 22(15):5803.
- [Emezie et al. 2024] Emezie, A. et al. (2024). Using heart rate and behaviors to predict effective intervention strategies for children on the autism spectrum: validation of a technology-based intervention. *Sensors*, 24(24):8024.
- [FAPESP 2021] FAPESP (2021). Prevenção de transtornos mentais entre estudantes pode evitar repetência e evasão escolar, aponta estudo. Acesso em: 05 out. 2024.
- [Gagniuc 2021] Gagniuc, P. A. (2021). *Markov Chains: From Theory to Implementation and Experimentation*. Wiley, Hoboken, NJ.
- [González Barral et al. 2025] González Barral, A. M. et al. (2025). Wearable sensors in paediatric neurology. *Developmental Medicine & Child Neurology*, 67(1):25–38.
- [Gulrajani and Lopez-Paz 2021] Gulrajani, I. and Lopez-Paz, D. (2021). In search of lost domain generalization. *Journal of Machine Learning Research*, 22(109):1–59.
- [Hoffmann 2023] Hoffmann, M. S. (2023). Prevenção de transtornos mentais entre estudantes pode evitar repetência e evasão escolar. INCT 2014: Psiquiatria do Desenvolvimento para Crianças e Adolescentes. Acesso em: 05 out. 2024.
- [Imbiriba et al. 2023] Imbiriba, T. et al. (2023). Wearable biosensing to predict imminent aggressive behavior in psychiatric inpatient youths with autism. *JAMA Network Open*, 6(12):e2348898.
- [Kim et al. 2022] Kim, S., Park, J., and Kim, Y. (2022). Physiological signal-based stress detection using ensemble machine learning models including random forest. *Sensors*, 22(4):1563.
- [Kleppmann 2022] Kleppmann, M. (2022). *Designing Data-Intensive Applications: The Big Ideas Behind Reliable, Scalable, and Maintainable Systems*. O'Reilly Media, Sebastopol, CA.

- [Kreibig et al. 2021] Kreibig, S. D. et al. (2021). Autonomic nervous system activity in emotion: An updated review. *Biological Psychology*, 164:108073.
- [Maghsudi et al. 2021] Maghsudi, S. et al. (2021). Personalized education in the artificial intelligence era: what to expect next. *IEEE Signal Processing Magazine*, 38(3):37–50.
- [Mantovani and Rossi 2021] Mantovani, R. G. and Rossi, A. L. (2021). Hyperparameter tuning of machine learning algorithms using scikit-learn and evolutionary optimization. *Applied Soft Computing*, 113:107874.
- [Mazefsky and White 2021] Mazefsky, C. A. and White, S. W. (2021). Emotion regulation: concepts and practice in autism spectrum disorder. *Child and Adolescent Psychiatric Clinics of North America*, 30(3):593–607.
- [MEC 2024] MEC (2024). Crescem matrículas de alunos com transtorno do espectro autista. Acesso em: 05 out. 2024.
- [Naik 2024] Naik, N. (2024). Mqtt protocol: The backbone of iot communication in 2024. EMQ Technologies blog. Acesso em: 05 out. 2024.
- [OASIS 2023] OASIS (2023). Mqtt version 5.0. OASIS Standard. Acesso em: 05 out. 2024.
- [Olinic et al. 2025] Olinic, M. S. et al. (2025). Wearables in adhd: monitoring and intervention—where are we now? *Diagnostics*, 15(18):2359.
- [Porges 2022] Porges, S. W. (2022). *Polyvagal Theory: A Science of Safety*. W. W. Norton & Company, New York.
- [Puli and Kushki 2020] Puli, A. and Kushki, A. (2020). Toward automatic anxiety detection in autism: a real-time algorithm for detecting physiological arousal in the presence of motion. *IEEE Transactions on Biomedical Engineering*, 67(3):646–657.
- [Rahman 2025] Rahman, M. M. (2025). Fitbit-derived measures for predicting adhd in adolescents. *Frontiers in Child and Adolescent Psychiatry*, 4.
- [Shorten et al. 2021] Shorten, C., Khoshgoftaar, T. M., and Furht, B. (2021). Text data augmentation for deep learning. *Journal of Big Data*, 8(1):1–34.
- [Sideraki and Anagnostopoulos 2025] Sideraki, A. and Anagnostopoulos, C. N. (2025). The use of artificial intelligence for intervention and education in autism spectrum disorder. arXiv preprint arXiv:2505.02747. Acesso em: 05 out. 2024.
- [Singh et al. 2022] Singh, J. et al. (2022). An observational study of heart rate variability using wearable sensors provides a target for therapeutic monitoring of autonomic dysregulation in patients with rett syndrome. *Biomedicines*, 10(7):1684.
- [Sousa et al. 2023] Sousa, A. C. et al. (2023). The use of wearable technologies in the assessment of physical activity in preschool- and school-age youth: systematic review. *International Journal of Environmental Research and Public Health*, 20(4):3402.
- [Tanenbaum and Van Steen 2023] Tanenbaum, A. S. and Van Steen, M. (2023). *Distributed Systems*. Pearson Education, Hoboken, NJ, 4th edition.
- [Tang et al. 2024] Tang, X. et al. (2024). Skin-interfacing wearable biosensors for smart health monitoring of infants and neonates. *Communications Materials*, 5(1):84.

- [UNESCO 1994] UNESCO (1994). Declaração de salamanca sobre princípios, política e prática em necessidades educativas especiais. Salamanca, Espanha. Acesso em: 05 out. 2024.
- [Vanschoren et al. 2023] Vanschoren, J. et al. (2023). Scikit-learn: machine learning in python — a modern review. *Journal of Machine Learning Research*, 24(326):1–9.
- [Zhou et al. 2023] Zhou, Y., Wang, J., Liu, S., and Li, Q. (2023). Random forest: a comprehensive review. *Artificial Intelligence Review*, 56:1235–1270.