

# PISCISAFE: SISTEMA IOT COM PREVISÃO DE PH VIA RANDOM FOREST PARA AQUICULTURA SUSTENTÁVEL

DANIELA FERREIRA<sup>1</sup>, MARIA CLARA FERNANDES<sup>1</sup>

<sup>1</sup>Faculdade SENAI Fatesg R. 227-A, 95- Setor Leste Universitario, Goiânia- GO

**Abstract.** Aquaculture has emerged as a strategic alternative to meet the growing global demand for animal protein, combining production efficiency with sustainability potential, yet it still relies on rigorous water quality monitoring, as small physicochemical variations can compromise fish welfare and cause economic losses. In this context, this work presents Piscisafe, an integrated Internet of Things (IoT) and Artificial Intelligence (AI) system designed for real-time monitoring and predictive analysis in aquaculture tanks. The system employs an ESP32 based sensor node that records water temperature, pH, and timestamp data, while real measurements are complemented with synthetic data to enhance training robustness. Among the evaluated models, the Random Forest Regressor demonstrated the most consistent performance for pH prediction and was therefore adopted in the final system. The project also includes an interactive Streamlit dashboard that provides dynamic visualizations, performance metrics, forecasts, and operational alerts. The results demonstrate the technical feasibility of Piscisafe and indicate that, when operating with full adherence to its recommendations, the system can stabilize environmental parameters in approximately 60% of the simulated scenarios, highlighting its potential as a decision-support tool for sustainable aquaculture management.

**Resumo.** A aquicultura tem se destacado como alternativa estratégica para suprir a crescente demanda global por proteína animal, conciliando eficiência produtiva e potencial de sustentabilidade, mas ainda depende de monitoramento rigoroso da qualidade da água, uma vez que pequenas variações físico-químicas podem comprometer o bem-estar dos peixes e gerar perdas econômicas. Neste contexto, este trabalho apresenta o Piscisafe, um sistema integrado de Internet das Coisas (IoT) e Inteligência Artificial (IA) voltado ao monitoramento contínuo e à análise preditiva em tanques aquícolas. O sistema utiliza um nó sensor baseado em ESP32 para registrar temperatura, pH e marca temporal das medições, combinando dados reais e sintéticos para ampliar a robustez do treinamento. Entre os modelos avaliados, o Random Forest Regressor apresentou desempenho mais consistente na previsão do pH, sendo implementado na solução final. O projeto inclui ainda um dashboard interativo em Streamlit, que fornece visualizações dinâmicas, previsões, métricas de desempenho e alertas operacionais. Os resultados demonstram a viabilidade técnica do Piscisafe e indicam que, operando em pleno funcionamento, o sistema é capaz de estabilizar parâmetros ambientais em aproximadamente 60% dos cenários simulados.

## **1. Introdução**

A aquicultura tem se consolidado como alternativa sustentável para suprir a crescente demanda por proteínas, mas ainda enfrenta vulnerabilidades relacionadas às condições ambientais e ao comportamento dos peixes, fatores que afetam diretamente a produtividade e a sustentabilidade dos cultivos (BARROSO et al., 2024; SILVA, 2024). Com a expansão de tecnologias de monitoramento e análise, como IoT, Big Data e Inteligência Artificial, torna-se possível substituir práticas manuais sujeitas a falhas por sistemas capazes de acompanhar o ambiente em tempo real e apoiar decisões operacionais mais precisas (DEBIAZI; MASIERO, 2023; VIDAL, 2023). Essa necessidade se reforça pelo papel central da qualidade da água na piscicultura (SALLUM et al., 2013).

Estudos ambientais evidenciam riscos decorrentes do manejo inadequado em tanques-rede, incluindo eutrofização, alterações na comunidade planctônica e mudanças comportamentais associadas ao acúmulo de matéria orgânica (CARVALHO; RAMOS, 2010). Esses processos afetam parâmetros físico-químicos, especialmente o pH, que influencia o metabolismo e a suscetibilidade dos peixes a estresse e doenças quando fora da faixa ideal (SANTOS et al., 2020). Assim, o pH torna-se um indicador sensível de possíveis desequilíbrios ecológicos e comportamentais, reforçando a importância de seu monitoramento contínuo.

Diante desse cenário, o PISCISAFE propõe um ecossistema digital que integra sensores e algoritmos de inteligência artificial para monitoramento contínuo da qualidade da água e identificação de padrões comportamentais. O sistema realiza detecção de anomalias, sugere ajustes operacionais e emite alertas em tempo real, correlacionando dados de temperatura, pH e variáveis produtivas a fatores como densidade populacional, competição alimentar e acúmulo de resíduos biológicos (GONÇALVES et al., 2025). Embora focado no suporte direto ao produtor, o sistema também considera, de forma complementar, o mapeamento de focos produtivos, uma vez que falhas no ordenamento espacial podem intensificar impactos ambientais (CARVALHO; RAMOS, 2010), contribuindo para práticas mais sustentáveis sem desviar do objetivo central de apoiar o manejo diário.

As próximas seções do artigo abordarão: (2) Trabalhos relacionados/Fundamentação Teórica, apontando para avaliação crítica e aprofundada de estudos e publicações existentes identificando o que já foi pesquisado, processos que envolvem buscas e análise, destacando pesquisas e tecnologias de IoT, IA e Big Data aplicadas a aquicultura. (3) Metodologia, detalhando o desenvolvimento do sistema, arquitetura de dados e algoritmos utilizados. (4) Resultados e discussões, apresentando os testes de desempenho e impacto da solução. Por fim, (5) Conclusões, enfatizando as contribuições para uma aquicultura mais eficiente, sustentável e inteligente.

## **2. Trabalhos Relacionados**

Nessa seção é exposta uma interrelação do projeto com outras propostas relevantes para o meio. O quadro mostra que o projeto integra variados pilares das tecnologias emergentes, evidenciando uma convergência entre métodos modernos de coleta, processamento e interpretação de dados ambientais. A comparação com trabalhos relacionados destaca aplicações que utilizam tecnologias de percepção distribuída baseadas em Internet das Coisas (IoT) e Automação (AU), bem como abordagens de análise e treinamento de modelos com Inteligência Artificial (AI).

Além disso, o projeto incorpora visualizações guiadas por indicadores-chave de desempenho, essenciais para a conservação e evolução do ambiente aquícola, por meio de Business Intelligence (BI), aliado a uma interface intuitiva (UI), sustentabilidade (SUS) como parâmetro central de avaliação e uma assistente virtual (VA) capaz de gerar resumos e alertas operacionais. Assim, consolida-se um sistema completo de monitoramento inteligente e sustentável, configurando um diferencial tanto na arquitetura quanto no processo de desenvolvimento. O Piscisafe avança ao propor uma arquitetura end-to-end, da coleta à tomada de decisão.

**Table 1. Comparação entre projetos relacionados e o PISCISAFE.**

Referência	IOT	AU	IA	BI	SUS	UI	VA
A – Gonçalves et al. (2025)	Sim	Sim	Sim	Não	Sim	Não	Não
B – Santos et al. (2025)	Sim	Não	Não	Não	Sim	Sim	Não
C – Barros et al. (2025)	Sim	Sim	Não	Não	Sim	Sim	Não
D – Saraiva et al. (2024)	Sim	Sim	Não	Não	Sim	Sim	Não
PISCISAFE	Sim						

Com relação ao estudo publicado por GONÇALVES et al.(2025), a aplicação de big data e IoT para análise gerencial, são aspectos fundamentais para a compreensão e implementação do conceito de piscicultura inteligente. Nesse aspecto, as Tecnologias 4.0 e o Business Intelligence (BI) são em suma, um pilar favorável para a gestão ágil na aquicultura e o desenvolvimento estratégico a partir da aplicação de Inteligência Artificial no monitoramento contínuo da qualidade da água e comportamento dos peixes.

De acordo com Santos (2025) no artigo AQUICULTURA 4.0: SISTEMA DE GERENCIAMENTO DE FAZENDA, o desenvolvimento de um sistema digital de gerenciamento para fazendas aquícolas. O trabalho identifica lacunas nos sistemas existentes no mercado, como alto custo, baixa usabilidade e pouca adaptação ao ambiente de campo, propondo uma ferramenta focada em acessibilidade, usabilidade mobile (Mobile-First) e registro offline, utilizando tecnologias modernas como React e TypeScript. O sistema busca suprir essas carências com módulos para planejamento zootécnico, biometria com visualização gráfica de crescimento, tabela de arraçoamento dinâmica e gestão de equipe, armazenando dados localmente para uso mesmo sem internet, promovendo maior eficiência e autonomia para pequenos e médios produtores.

O artigo "A precisão da contagem de alevino: contador de peixes na piscicultura" de Barros et al.(2025), discute a piscicultura sob a ótica das limitações operacionais que comprometem a contagem manual de alevinos, destacando como erros humanos e o alto tempo de execução afetam diretamente o manejo e a eficiência produtiva. O estudo apresenta um protótipo automatizado baseado em Arduino e sensores LDR, capaz de registrar a passagem dos peixes com precisão e em tempo real, oferecendo uma alternativa de baixo custo alinhada aos conceitos da Indústria 4.0.

No trabalho " AquaFeed: Um Sistema de Monitoramento dos Parâmetros Físico-Químicos e Recomendação para Auxílio do Manejo Alimentar na Piscicultura", de Saraiva (2024), aborda a necessidade de tecnologias acessíveis para a piscicultura, propondo um sistema integrado. Este combina hardware para monitoramento em tempo real

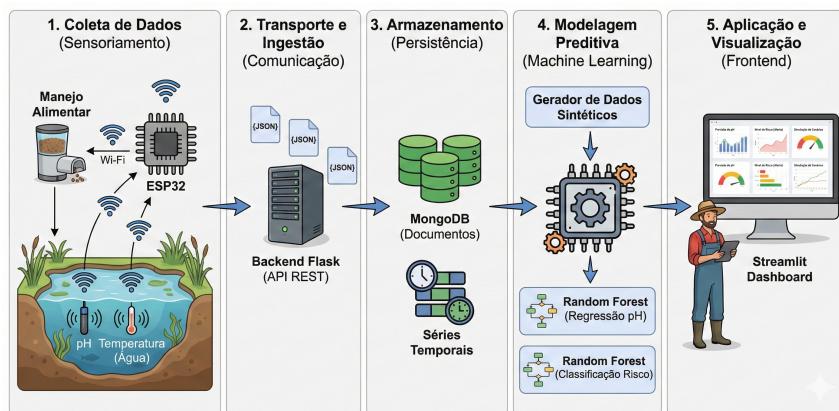
de temperatura, pH, oxigênio dissolvido e condutividade elétrica, com um software que emprega algoritmos de aprendizado de máquina para recomendar a alimentação diária da espécie tambaqui, considerando o peso dos peixes e a temperatura da água. Avaliado com sucesso em laboratório e campo contra sensores comerciais, o sistema visa oferecer uma solução de baixo custo para otimizar o manejo e a produtividade (Saraiva, 2024).

Visando valorizar, inovar e evoluir, o PISCISAFE propõe uma interface integrada capaz de conectar a máquina a um sistema inteligente de treinamento, permitindo aprimorar a percepção sobre o ambiente da piscicultura. A solução oferece praticidade e uma experiência intuitiva por meio de um aplicativo que atualiza e exibe dashboards e mensagens sobre o status da qualidade da água, contribuindo para o aumento da produtividade e da eficiência na produção. Além disso o Piscisafe busca prever cenários de risco e antecipar cenários críticos e evitá-los no longo prazo. Sobretudo, com tecnologias que integram o usuário como principal analista e promotor da sua fazenda, garantindo controle e assecibilidade.

Em síntese o PISCISAFE, se comunica com o produtor a partir de uma assistente virtual, sendo um grande diferencial na usabilidade referente aos outros trabalhos, estuda continuamente os mais diversos cenários e prevê riscos com até 69% de precisão com um prazo de até 3 anos. Além disso, conecta o psicultor a uma consciência espacial sobre quais locais são recomendados para investir e onde pode ser de grande risco para o meio ambiente, promovendo sustentabilidade e planejamento autônomo de negócios para expansão.

### 3. Arquitetura PISCISAFE

A arquitetura metodológica do PISCISAFE foi estruturada em cinco camadas funcionais, representadas na figura, que organizam o fluxo de dados desde a percepção física do ambiente até a entrega das inferências de risco ao usuário. Essa abordagem em camadas foi adotada por permitir modularidade, substituição independente de componentes e escalabilidade para contextos reais de produção aquícola.



**Figure 1. Arquitetura em Camadas**

A primeira camada compreende os sensores responsáveis pela captura das variáveis ambientais, garantindo padronização e estabilidade temporal mesmo com diferentes tipos de dispositivos. Em seguida, a camada de conexão estabelece o transporte dos

dados via Wi-Fi em formato JSON, permitindo também futura adaptação para Bluetooth ou redes celulares sem alterar o restante da arquitetura. Já a camada de armazenamento registra as medições em um banco orientado a documentos, possibilitando flexibilidade de schema, inclusão de sensores opcionais e construção de uma série temporal consistente tanto do ponto de vista do dispositivo quanto do servidor.

A camada de treinamento utiliza modelos de Random Forest para previsão do pH e classificação do risco, operando sobre essa base histórica robusta. Técnicas como divisão estratificada, comparação com baselines, ablação de atributos e controle de overfitting garantem maior confiabilidade às inferências. Por fim, a camada de aplicação organiza esses resultados em dashboards interativos, que atualmente validados em interface web, mas previstos para migração ao Kivy, permitindo análises mais intuitivas em campo e dando suporte direto à tomada de decisão. Dessa forma, o pipeline do PISCISAFE conecta sensores, comunicação IoT, armazenamento estruturado, aprendizado de máquina e visualização aplicada em um fluxo único, modular e escalável.

## 4. Metodologia

### 4.1. Coleta e Armazenamento dos dados

A camada de percepção do PISCISAFE é estruturada a partir de um nó físico baseado em ESP32, responsável pela coleta contínua dos parâmetros essenciais de qualidade da água. O microcontrolador opera conectado via Wi-Fi e sincronizado por NTP, garantindo registros temporais precisos e padronizados. Essa escolha assegura baixo custo, alta disponibilidade e facilidade de replicação em diferentes ambientes de piscicultura, permitindo que o sistema funcione tanto em tanques experimentais quanto em estruturas produtivas maiores.

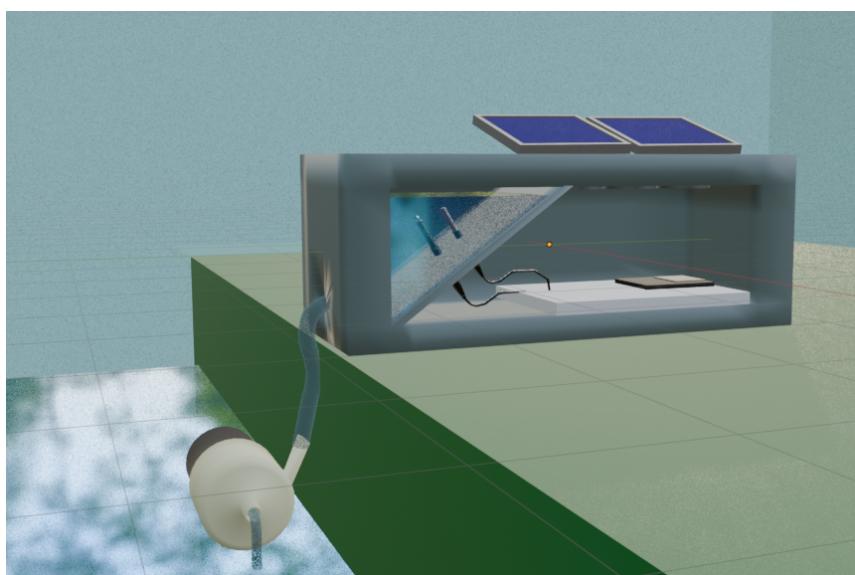


Figure 2. Projeção em 3D

Dois sensores compõem o módulo primário de leitura: o pH4502C, empregado para medir o potencial hidrogeniônico, e o DS18B20, utilizado para aferir a temperatura da água. O pH4502C opera com base em eletrodos de vidro sensíveis à concentração

de íons H, traduzindo variações químicas em diferenças de potencial elétrico, o que permite detectar alterações fisiologicamente relevantes para os peixes. Já o DS18B20 utiliza princípios de semicondutores com coeficientes térmicos calibrados, assegurando medições estáveis mesmo em ambientes com oscilações bruscas de temperatura. A combinação desses dois sensores fornece uma representação sólida das condições físico-químicas do ambiente, permitindo inferir comportamentos anômalos e identificar indícios de estresse ou risco sanitário.

O nó de percepção conta ainda com alimentação por painel solar, ampliando a autonomia energética do sistema, e com um módulo de bombeamento que renova periodicamente a água do reservatório interno, garantindo que as medições representem condições reais do tanque de cultivo. Um servo motor acoplado à válvula de entrada regula a renovação hídrica nos instantes programados, caracterizando o ciclo de início e fim de cada processo de leitura. Essa lógica evita acúmulo de resíduos no microambiente do sensor e reduz deriva eletroquímica, aumentando a confiabilidade das medições.

Os dados capturados são imediatamente estruturados em formato JSON e enviados pela rede local, o que simplifica a integração e facilita a adição futura de novos sensores com mínima intervenção no código. No backend, a API Flask valida e armazena essas medições no MongoDB, criando uma base consistente, escalável e rastreável. Esse fluxo garante padronização do formato, precisão temporal e redução de ruídos, fatores essenciais para evitar overfitting e underfitting durante o treinamento dos modelos. A estrutura integrada entre ESP32, Flask e MongoDB forma uma cadeia leve, modular e preparada para análises estatísticas e aprendizado de máquina em escala.

#### **4.2. Geração de dados sintéticos para treinamento.**

O módulo de geração de dados sintéticos do PISCISAFE produz uma base artificial totalmente alinhada ao formato utilizado no sistema, simulando condições reais de um viveiro aquícola. Para cada horário do ciclo diário, o script cria registros que incluem temperatura da água, oferta de ração, qualidade do insumo, pH estimado e crescimento dos peixes, sempre dentro de faixas e padrões inspirados no manejo real. A temperatura segue variações típicas do ciclo térmico diário, a alimentação ocorre em horários definidos e o pH é calculado a partir de combinações entre temperatura, quantidade de ração e sua qualidade. O modelo também verifica automaticamente se o diâmetro do pellet é adequado ao peso simulado dos animais.

A simulação incorpora elementos determinísticos e estocásticos para reproduzir tanto o comportamento esperado do sistema quanto suas variações inesperadas, formando um conjunto de dados mais rico e realista. Além disso, os registros são gerados com timestamps consistentes ao longo do período escolhido, permitindo a criação de séries temporais completas e coerentes. O resultado é uma base variada, estruturada e pronta para servir às etapas de unificação dos dados, treinamento dos modelos e testes iniciais de regressão e classificação de risco.

#### **4.3. Mapeamento de Zonas Aquícolas**

O sistema incorpora um procedimento de mapeamento espacial implementado no Google Earth Engine (GEE), onde séries temporais de imagens Sentinel-2 e Landsat 8 são processadas para identificar corpos d'água por meio do índice espectral NDWI. As imagens são

submetidas a composição temporal, cálculo de bandas derivadas e segmentação binária, permitindo isolar superfícies hídricas de forma automatizada. Em seguida, filtros espaciais e temporais são aplicados para remover ruídos e consolidar polígonos com estabilidade sazonal, resultando em camadas vetoriais representativas do ambiente. Essas geometrias são exportadas do GEE e constituem a base para caracterização sistemática das áreas potencialmente adequadas à piscicultura, sem interferir no monitoramento *in situ*.

Após a exportação, os vetores são processados localmente em Python, onde passam por validação topológica, padronização e vinculação a metadados ambientais derivados das imagens orbitais. As camadas resultantes são indexadas espacialmente e integradas ao backend do Piscisafe por meio de rotinas automatizadas, viabilizando sua visualização no dashboard. Bibliotecas como GeoPandas e Folium são utilizadas para transformar os polígonos em mapas interativos acessíveis ao usuário final. A conexão não requer APIs adicionais além do GEE, uma vez que os dados vetoriais são consumidos diretamente pela aplicação, permitindo incorporar informações de detecção remota ao sistema de forma reproduzível e metodologicamente consistente.

O sistema também utiliza os polígonos mapeados para estimar áreas de adensamento produtivo, nas quais a concentração excessiva de viveiros pode indicar risco ambiental. A partir de métricas como densidade espacial e variação temporal de uso, esses dados são convertidos em atributos para um modelo Random Forest, permitindo identificar padrões associados a potenciais zonas de saturação aquícola.

#### 4.4. Modelagem e Interface

Na etapa de modelagem, os dados do arquivo foram organizados em estruturas adequadas à análise, permitindo ordenar séries temporais, extrair atributos derivados do tempo e preparar variáveis para o aprendizado de máquina. Em seguida, os modelos de regressão e classificação foram construídos a partir de pipelines que combinam pré-processamento e Random Forest, escolhidos pela boa capacidade de lidar com dados mistos, ruídos e relações não lineares, entregando desempenho estável sem necessidade de ajustes complexos.

No módulo de regressão, o Random Forest emprega o erro quadrático médio (MSE) como critério interno para a definição das divisões nas árvores que compõem o ensemble. Em cada nó candidato, o algoritmo calcula a redução do MSE selecionando a partição que minimiza a variabilidade residual das respostas. Essa estratégia orienta o modelo a produzir subdivisões mais homogêneas e, portanto, previsões mais estáveis do pH futuro. Embora o treinamento utilize o MSE como função de custo, a avaliação externa do desempenho adota o MAE, que mantém interpretação direta na escala da variável, complementando a robustez do processo de aprendizagem.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$$

**Figure 3. Fórmula Erro Quadrático Médio (MSE)**

Para avaliar o desempenho preditivo do modelo de regressão aplicado ao pH, os dados foram particionados em conjuntos de treinamento e teste utilizando divisão hold-out (80/100 e 20/100, respectivamente), preservando a distribuição estatística das variáveis. Essa etapa garante que o algoritmo aprenda padrões gerais a partir do conjunto de treinamento, enquanto o conjunto de teste permanece isolado do processo de ajuste, funcionando como uma estimativa imparcial de desempenho em dados nunca vistos — condição essencial para evitar sobreajuste (overfitting) e medir a capacidade real de generalização do modelo.

A métrica adotada para quantificar o erro da regressão foi o Mean Absolute Error (MAE), que expressa a média das diferenças absolutas entre os valores previstos e observados do pH. O MAE é particularmente adequado para dados ambientais porque (i) penaliza todos os desvios de forma linear, sem amplificação artificial de outliers, (ii) mantém a interpretação direta na escala da variável medida e (iii) permite verificar com clareza se o erro médio permanece dentro de limites fisiológicos aceitáveis para a fauna cultivada. Assim, um MAE baixo indica que as previsões do modelo seguem de perto as variações reais da série temporal, dando suporte a decisões operacionais baseadas em pequenas flutuações do pH.

A interface interativa foi desenvolvida em Streamlit, integrando visualização dos dados, treinamento dos modelos e simulação de cenários em um único ambiente. Por meio de controles intuitivos, o usuário ajusta variáveis como temperatura, ração e horário, obtendo imediatamente a previsão de pH futuro e o nível de risco. Assim, o conjunto das ferramentas adotadas oferece agilidade, simplicidade e fluxo contínuo entre dados, modelos e visualização, reforçando a proposta do PISCISAFE de transformar medições ambientais em informação prática e acessível.

## 5. Testagem, Validação e Resultados

### 5.1. Dados Sintéticos

A utilização de dados fictícios influencia diretamente os resultados obtidos, uma vez que sua distribuição e variabilidade condicionam o comportamento do modelo. Assim, o planejamento criterioso da geração desses dados torna-se indispensável. Para o treinamento de modelos de regressão baseados em Random Forest, é necessária uma amostra suficientemente diversa para permitir que o algoritmo aprenda relações significativas. Caso essa diversidade não exista, o modelo tende a reproduzir padrões artificiais, deixar de identificar comportamentos aproximados da realidade ou ainda falhar na previsão de cenários de risco futuro.

Como solução, optou-se por recalibrar o algoritmo de geração sintética de dados, de modo a aumentar sua adaptabilidade frente a situações recorrentes em escalas sazonais e anuais. A construção desse mecanismo considerou variações ambientais típicas das estações do ano, bem como a influência de anomalias climáticas relevantes, como eventos associados a El Niño e La Niña, cuja literatura comprova impacto direto sobre temperatura, oxigenação e parâmetros físico-químicos da água.

No modelo implementado, tais efeitos são incorporados por meio de funções senoidais que representam ciclos térmicos sazonais e variações circadianas, além de tendências anuais definidas em uma tabela paramétrica. O pH é calculado como



**Figure 4. Gráfico de variação do ph**

combinação linear de múltiplos fatores, incluindo temperatura, quantidade e qualidade da ração, ruído ambiental e modificadores climáticos, permitindo que o conjunto gerado apresente heterogeneidade realista.

## 5.2. Mapa de localização de lagos

Os testes iniciais revelaram instabilidade nas geometrias derivadas do NDWI no Google Earth Engine, incluindo ruídos sazonais, polígonos fragmentados e inconsistências na delimitação dos corpos d'água. Esses problemas foram mitigados por meio do ajuste dos limiares espectrais, aplicação de filtros temporais mais rigorosos e revisão do processo de segmentação, garantindo que apenas superfícies hídricas persistentes fossem mantidas. A etapa seguinte, já em Python, evidenciou falhas topológicas e variações geométricas após a exportação, demandando rotinas de validação, padronização e correção com GeoPandas.



**Figure 5. Mapeamento de Lagos com geração de polígonos**

Com essas intervenções, os vetores foram estabilizados e integrados ao backend do sistema, permitindo sua utilização de forma consistente no dashboard e nas análises subsequentes. A melhoria estrutural das geometrias elevou a qualidade das métricas espaciais calculadas e tornou mais robusta a conversão desses atributos para o modelo Random

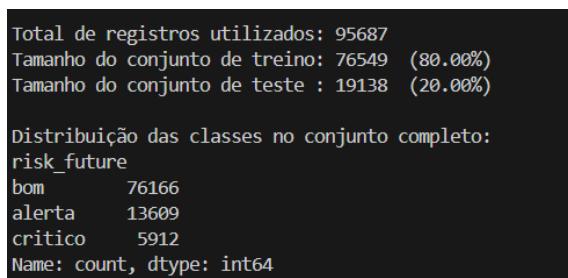


**Figure 6. Mapeamento de Lagos sem geração de polígonos**

Forest, resultando em uma solução final metodologicamente coerente e adequada ao diagnóstico de risco e adensamento produtivo em ambientes aquáticos.

### 5.3. Treinamento de Máquina

Para o treinamento do modelo, foi utilizada uma base final contendo 95.687 registros, a qual foi dividida em conjuntos de treino (80%) e teste (20%), preservando a proporção entre as classes por meio de stratified split. Essa estratégia assegura que a distribuição das categorias (bom, alerta e crítico) seja mantida em ambos os subconjuntos, reduzindo viés e melhorando a capacidade de generalização. No conjunto completo, observou-se predominância da classe bom (76.166 registros), seguida por alerta (13.609) e crítico (5.912), caracterizando um cenário moderadamente desbalanceado, comum em problemas ambientais.



**Figure 7. Visor do Progresso do treinamento**

Após a divisão, o conjunto de treino permaneceu com 60.932 registros da classe bom, 10.887 de alerta e 4.730 de crítico, enquanto o conjunto de teste reteve 15.234, 2.722 e 1.182 registros, respectivamente. O modelo Random Forest foi ajustado tanto para regressão quanto para classificação, permitindo capturar relações não lineares entre as variáveis ambientais e o risco futuro estimado pelo sistema. Na etapa de avaliação, o modelo regressivo apresentou MAE = 0,630, indicando boa aderência na previsão de valores contínuos. Já a versão classificatória obteve acurácia de 0,687, desempenho consistente considerando o desbalanceamento relativo das classes e a complexidade dos padrões.

```

Distribuição das classes no conjunto de TREINO:
risk_future
bom      60932
alerta    10887
critico   4730
Name: count, dtype: int64

Distribuição das classes no conjunto de TESTE:
risk_future
bom      15234
alerta    2722
critico   1182
Name: count, dtype: int64

```

**Figure 8. Visor do Progresso do treinamento**

ambientais associados ao risco aquícola. Esses resultados indicam que o modelo é capaz de reconhecer tendências relevantes nos dados e fornece previsões suficientemente robustas para apoiar o diagnóstico operacional do Piscisafe.

#### 5.4. Assistente Virtual

A versão inicial da assistente virtual apresentava limitações na geração de relatórios, exibindo apenas um resumo geral do cenário, sem distinção entre tanques ou análise contextualizada dos dados. Isso reduzia a capacidade interpretativa do sistema, dificultando a identificação de padrões operacionais relevantes e restringindo o suporte ao produtor. Além disso, a primeira implementação não integrava métricas preditivas ao relatório, impossibilitando que a assistente traduzisse os resultados do modelo em recomendações práticas.



**Figure 9. AV Relatório resultado simples**

A versão aprimorada solucionou essas limitações ao implementar uma rotina estruturada de geração de relatórios completos por tanque, capaz de calcular faixas de pH, identificar tendências e incorporar métricas de risco derivadas do modelo de classificação. O sistema passou a incluir interpretações automáticas e recomendações operacionais, tornando o relatório mais informativo e alinhado às necessidades do manejo. Dessa forma, a assistente evoluiu de um resumo estático para uma ferramenta analítica contextualizada, integrando dados históricos, métricas do modelo e análise interpretativa em um único componente.

### 6. Ética e Valores Jurídicos

A operação do Piscisafe envolve a coleta e análise de dados ambientais e produtivos relevantes para a atividade aquícola. Embora não contenham informações pessoais sensíveis, esses dados possuem caráter estratégico por refletirem práticas de manejo e indicadores

# Piscisafe 🐟 — Dashboard Inteligente

## ◎ Assistente Virtual Piscisafe

The screenshot shows the Piscisafe intelligent dashboard interface. At the top, there are three tabs: 'Resumo' (Summary), 'Relatório' (Report) which is highlighted with a red border, and 'Métricas' (Metrics). Below the tabs, a section titled 'RELATÓRIO DO TANQUE T1' displays the following information:

- Faixa de pH: • Mínimo = 3.70 • Máximo = 11.57 • Média = 7.55
- Resumo do Cenário:
  - pH médio: 7.55 • Temperatura média: 26.01°C • Bom: 76166 • Alerta: 13609 • Crítico: 5912
- Interpretação: Tendência de estabilidade do pH.
- Recomendações:
  - Acompanhar oscilações a cada 3h.
  - Revisar alimentação.
  - Checar sensor se houver instabilidade.

Pergunte ao sistema:

**Figure 10. AV com Relatório integrado com sugestões**

operacionais. Em conformidade com a LGPD, o sistema adota medidas de proteção como anonimização, controle de acesso e armazenamento seguro, assegurando que os registros sejam utilizados exclusivamente para fins analíticos e de monitoramento.

Do ponto de vista metodológico, o sistema enfrenta limitações típicas de ecossistemas IoT, incluindo dependência de conectividade estável, possibilidade de lacunas nas séries temporais e deriva instrumental de sensores eletroquímicos, que exige calibração periódica para manter a confiabilidade metrológica. Aspectos energéticos também podem afetar a continuidade das medições em cenários onde o nó sensor não dispõe de alimentação elétrica constante.

Além disso, o desempenho dos modelos de aprendizado de máquina requer monitoramento contínuo, uma vez que classificações incorretas podem introduzir vieses interpretativos. A robustez preditiva depende de ajustes regulares e validação com dados atualizados. Embora os resultados iniciais indiquem elevada viabilidade técnica, a consolidação do Piscisafe como ferramenta científica de apoio ao manejo depende da expansão de bases empíricas e da realização de testes prolongados em ambientes produtivos reais.

## 7. Conclusão

A aplicação de sistemas inteligentes à aquicultura reforça o potencial das tecnologias 4.0 para superar limitações tradicionais do manejo manual e pouco integrado. No contexto do PISCISAFE, a combinação entre coleta sensorial contínua, processamento distribuído em IoT, modelagem estatística e algoritmos de aprendizado de máquina demonstrou capacidade concreta de transformar medições ambientais em indicadores operacionais de risco.

Esse fluxo unificado, que integra desde a aquisição dos dados até a visualização preditiva, apresenta uma arquitetura moderna e escalável, alinhada às necessidades práticas da aquicultura sustentável, permitindo antecipar anomalias, reduzir perdas e favorecer o bem-estar dos peixes.

Os resultados obtidos na prova de conceito, incluindo a integração entre ESP32, API Flask e armazenagem no MongoDB, evidenciam maturidade técnica na cadeia de coleta e transmissão. Da mesma forma, o desempenho dos modelos Random Forest, tanto na previsão de pH quanto na classificação de risco, demonstrou acurácia consistente mesmo diante da variabilidade ambiental e do desbalanceamento natural das classes. Em conjunto, esses elementos consolidam o PISCISAFE como uma solução integradora que une detecção remota, automação e inteligência artificial, contribuindo para um manejo mais eficiente, inteligente e ambientalmente responsável, além de abrir novas perspectivas para evolução tecnológica e pesquisa aplicada na área.

## 8. References

### 8.1. Introdução

GONÇALVES , T. F.; OBANDO, J. M. C.; CHIAVANI JÚNIOR, L. C.; ANDRADE-SANTOS, A. P.; SILVA, E. C. F.; SANTOS, T. C. dos; NAOE, R. K.; TERAMOTO, Érico T.; BUENO, G. W. Piscicultura inteligente: a integração das Tecnologia 4.0 e “Business Intelligence” para gestão ágil na aquicultura. Revista de Gestão e Secretariado, [S. l.], v. 16, n. 1, p. e4524, 2025. DOI: 10.7769/gesec.v16i1.4524. Disponível em: <https://ojs.revistagesec.org.br/secretariado/article/view/4524>.

DA SILVA NASCIMENTO, Ana Juvelina; DENADAI, Marcelo Scantamburlo. Piscicultura no Brasil. Tekhne e Logos, v. 15, n. 1, p. 15-24, 2024.

DEBIAZI, Pedro Renan; MASIERO, E. A contribuição da inteligência artificial, Big Data e Internet das Coisas para o estudo do clima urbano em Smart Cities. Anais do 16º Encontro Nacional de Conforto no Ambiente Construído. São Paulo: Antac, 2023.

VIDAL, Victor Matheus de Oliveria et al. Sistema de monitoramento e controle modular do ambiente de produção da piscicultura. 2023.

DE FARIA, RHS et al. Criação de peixes em viveiros. Brasília. Codevasf , pág. 54-65, 2013.

RAMOS, Igor Paiva et al. Impactos ambientais de pisciculturas em tanques-rede sobre águas continentais brasileiras: revisão e opinião. Tópicos especiais em biologia aquática e aquicultura III. Jaboticabal: Sociedade Brasileira de Biologia Aquática, p. 87-98, 2010.

CARVALHO, Edmir Daniel; RAMOS, Igor Paiva. A aquicultura em grandes represas brasileiras: interfaces ambientais, socioeconômicas e sustentabilidade. 2010.

SOUZA, Antonio Carlos Freitas et al. Piscicultura no estado do Maranhão: perspectivas para aceleração da produção de peixes nativos. Scientia Plena, v. 18, n. 2, 2022.

## **8.2. Trabalhos Relacionados**

GONÇALVES , T. F.; OBANDO, J. M. C.; CHIAVANI JÚNIOR, L. C.; ANDRADE-SANTOS, A. P.; SILVA, E. C. F.; SANTOS, T. C. dos; NAOE, R. K.; TERAMOTO, Érico T.; BUENO, G. W. Piscicultura inteligente: a integração das Tecnologia 4.0 e “Business Intelligence” para gestão ágil na aquicultura. Revista de Gestão e Secretariado, [S. l.], v. 16, n. 1, p. e4524, 2025. DOI: 10.7769/gesec.v16i1.4524. Disponível em: <https://ojs.revistagesec.org.br/secretariado/article/view/4524>.

SANTOS, Pedro Roger Alves Dos. AQUICULTURA 4.0: SISTEMA DE GERENCIAMENTO DE FAZENDA.. FORTALEZA: UNIVERSIDADE FEDERAL DO CEARÁ CENTRO DE CIÊNCIAS AGRÁRIAS DEPARTAMENTO DE ENGENHARIA DE PESCA CURSO DE GRADUAÇÃO EM ENGENHARIA DE PESCA, 2025.

BARROS, Luana Oliveira et al. A precisão da contagem de alevino: contador de peixes na piscicultura com uso de tecnologia. Brazilian Journal of Development, v. 11, n. 4, p. e79242-e79242, 2025.

SARAIVA, Isaías Abner Lima. AquaFeed: um sistema de monitoramento de parâmetros Físico-Químicos e recomendação para auxílio ao manejo alimentar na Piscicultura. 2024.